

Hamiltonian Monte Carlo for Hierarchical Models

Michael Betancourt and Mark Girolami

Guilherme C. Soares

Ideia central do artigo

Pergunta

Por que modelos hierárquicos são difíceis para métodos MCMC tradicionais?

Resposta

Porque a estrutura hierárquica induz geometrias posteriores difíceis: correlações locais, curvatura variável e regiões tipo “funil”.

Proposta

Hamiltonian Monte Carlo usa gradientes e trajetórias “físicas” para explorar melhor essas geometrias, reduzindo o comportamento de passeio aleatório.

Modelo hierárquico básico

Um modelo hierárquico de um nível pode ser escrito como:

$$\pi(\theta, \phi \mid D) \propto \prod_{i=1}^n \pi(D_i \mid \theta_i) \pi(\theta_i \mid \phi) \pi(\phi).$$

- θ_i : parâmetros locais.
- ϕ : parâmetros globais.
- Os grupos compartilham informação por meio de ϕ .

Interpretação

A hierarquia permite **partial pooling**: cada grupo mantém sua heterogeneidade, mas aprende com os demais.

Exemplo: modelo normal hierárquico

O exemplo base do artigo é:

$$\begin{aligned}y_i &\sim \mathcal{N}(\theta_i, \sigma_i^2), \\ \theta_i &\sim \mathcal{N}(\mu, \tau^2), \quad i = 1, \dots, l.\end{aligned}$$

Aqui:

$$\phi = (\mu, \tau), \quad \theta = (\theta_1, \dots, \theta_l).$$

Problema

Quando os dados são fracos, τ controla fortemente a escala dos θ_i , gerando uma posterior com geometria difícil.

HIERARCHICAL MODELS

$$v \sim \mathcal{N}(0, 3^2), \quad \theta_i | v \sim \mathcal{N}(0, e^v).$$

- Se v é grande, a variância dos θ_i é grande.
- Se v é pequeno, os θ_i ficam comprimidos perto de zero.
- A posterior combina regiões de grande volume com regiões de alta densidade.

Atenção

Uma pequena mudança no parâmetro global v muda fortemente a geometria local da posterior.




FIG. 3. One of the biggest challenges with modern models is not global correlations but rather local correlations that are resistant to the corrections based on the global covariance. The funnel distribution, here with $N = 100$, features strongly varying local correlations but enough symmetry that these correlations cancel globally, so no single correction can compensate for the ineffective exploration of (a) the Gibbs sampler and (b) Random Walk Metropolis. After 2500 iterations neither chain

HIERARCHICAL MODELS




FIG. 3. One of the biggest challenges with modern models is not global correlations but rather local correlations that are resistant to the corrections based on the global covariance. The funnel distribution, here with $N = 100$, features strongly varying local correlations but enough symmetry that these correlations cancel globally, so no single correction can compensate for the ineffective exploration of (a) the Gibbs sampler and (b) Random Walk Metropolis. After 2500 iterations neither chain

As setas verdes representam direções locais de curvatura da log-posterior.

$$\nabla^2 \log p(\theta_1, \dots, \theta_n, v).$$

- A direção das setas muda ao longo do funil.
- O tamanho das setas reflete a intensidade da curvatura.
- A geometria é diferente na parte larga e no gargalo.

Mensagem

Não existe uma única rotação ou reescalonamento global que resolva toda a geometria do funil.

Por que Gibbs e Metropolis Falham?

- Esses algoritmos exploram a distribuição por meio de movimentos locais.
- Em distribuições correlacionadas, as variâncias condicionais podem ser muito menores que as marginais.
- Em modelos hierárquicos, a curvatura da posterior varia fortemente ao longo do espaço de parâmetros.
- Como consequência, os algoritmos acabam se comportando como passeios aleatórios.

Importante

O principal desafio dos modelos hierárquicos não é apenas a correlação entre parâmetros, mas a forte variação da geometria local da posterior.

Parametrização centrada

No modelo normal hierárquico, a parametrização centrada é:

$$y_i \sim \mathcal{N}(\theta_i, \sigma_i^2),$$

$$\theta_i \sim \mathcal{N}(\mu, \tau^2).$$

Quando funciona melhor?

Quando os dados são informativos o bastante para identificar bem cada θ_i .

Quando falha?

Quando os dados são fracos, θ_i e τ ficam fortemente dependentes, gerando geometria tipo funil.

Parametrização não centrada

A parametrização não centrada reescreve:

$$\theta_i = \mu + \tau \vartheta_i,$$

com

$$\vartheta_i \sim \mathcal{N}(0, 1).$$

Então:

$$y_i \sim \mathcal{N}(\mu + \tau \vartheta_i, \sigma_i^2).$$

Ideia

A dependência hierárquica é deslocada para uma transformação determinística, reduzindo a correlação entre os parâmetros diretamente amostrados.

Por que a parametrização não centrada funciona?

4




FIG. 4. In one-level hierarchical models with global parameters, ϕ , local parameters, θ , and measured data y , correlations between parameters can be mediated by different parameterizations of the model. Non-centered parameterizations exchange a direct dependence between ϕ and θ for a dependence between ϕ and y ; the reparameterized ϑ and ϕ become independent conditioned on the data. When the data are weak these non-centered parameterizations yield simpler posterior geometries.

Interpretação

A parametrização não centrada troca uma dependência direta entre ϕ e θ por uma dependência entre ϕ e os dados.

Centrada versus Não Centrada

Parametrização centrada

$$\theta_i \sim \mathcal{N}(\mu, \tau^2),$$

$$y_i \sim \mathcal{N}(\theta_i, \sigma_i^2).$$

- A dependência hierárquica aparece diretamente na prior.
- A geometria da posterior é dominada pela estrutura hierárquica.
- Pode induzir fortes correlações entre parâmetros locais e globais.

Parametrização não centrada

$$\theta_i = \mu + \tau \vartheta_i,$$

$$\vartheta_i \sim \mathcal{N}(0, 1).$$

$$y_i \sim \mathcal{N}(\mu + \tau \vartheta_i, \sigma_i^2).$$

- A dependência hierárquica é deslocada para a transformação determinística.
- Os parâmetros latentes possuem escala fixa.
- A geometria induzida pela prior torna-se mais regular.

Quando cada parametrização funciona melhor?

- Quando os dados são altamente informativos, a verossimilhança domina a posterior.
- Nesse caso, a parametrização centrada tende a produzir uma geometria mais favorável.
- Quando os dados são fracamente informativos, a prior hierárquica domina a posterior.
- Nesse caso, a parametrização não centrada reduz a dependência induzida pela hierarquia e pode melhorar drasticamente a eficiência.

Ideia central

Não existe parametrização universalmente melhor.

A melhor escolha depende do balanço entre a informação dos dados e a informação introduzida pela hierarquia.

Construindo um Sistema Hamiltoniano

Considere uma distribuição alvo

$$\pi(q),$$

onde q representa os parâmetros do modelo. Introduzimos variáveis auxiliares de momento

$$p,$$

e definimos uma distribuição conjunta

$$\pi(p, q) = \pi(p \mid q)\pi(q).$$

A distribuição marginal de interesse permanece

$$\int \pi(p, q) dp = \pi(q).$$

Ideia

Ao aumentar o espaço de estados, podemos explorar a distribuição alvo utilizando ferramentas da mecânica Hamiltoniana.

Energia Potencial e Energia Cinética

Definimos o Hamiltoniano como

$$H(p, q) = -\log \pi(p, q).$$

Separando os termos,

$$H(p, q) = -\log \pi(p \mid q) - \log \pi(q).$$

Logo,

$$H(p, q) = T(p \mid q) + V(q),$$

onde

$$T(p \mid q) \equiv -\log \pi(p \mid q)$$

é a energia cinética, e

$$V(q) \equiv -\log \pi(q)$$

é a energia potencial.

Dinâmica Hamiltoniana

O algoritmo primeiro amostra os momentos auxiliares:

$$p \sim \pi(p \mid q).$$

Depois, evolui o sistema conjunto usando as equações de Hamilton:

$$\frac{dq}{dt} = +\frac{\partial H}{\partial p} = +\frac{\partial T}{\partial p},$$

$$\frac{dp}{dt} = -\frac{\partial H}{\partial q} = -\frac{\partial T}{\partial q} - \frac{\partial V}{\partial q}.$$

Interpretação

Os gradientes guiam as transições por regiões de alta probabilidade, permitindo uma exploração eficiente da distribuição alvo.

Tempo de Integração

As equações de Hamilton definem uma trajetória determinística no espaço aumentado (p, q) .

- A trajetória deve ser integrada por algum tempo.
- O tempo ótimo depende da forma da distribuição alvo.
- Esse tempo pode variar com a posição no espaço de parâmetros.

Problema

Escolher dinamicamente o tempo de integração não é trivial: implementações ingênuas podem quebrar o balanço detalhado.

Solução usada em prática

O No-U-Turn Sampler preserva o balanço detalhado integrando não apenas para frente no tempo, mas também para trás.

Por que HMC é eficiente?

As trajetórias Hamiltonianas conseguem percorrer escalas compatíveis com as variâncias marginais da distribuição alvo.

- Isso elimina boa parte do comportamento de passeio aleatório.
- A eficiência persiste mesmo quando a distribuição alvo é correlacionada.
- Isso é especialmente relevante em modelos hierárquicos, onde as correlações são majoritariamente locais.

Mensagem do artigo

O HMC pode explorar de forma eficiente distribuições difíceis, mas modelos hierárquicos ainda apresentam desafios dependendo da escolha de $\pi(p | q)$.

Euclidean Hamiltonian Monte Carlo

A escolha mais simples e mais comum para os momentos é uma Gaussiana independente de q :

$$\pi(p \mid q) = \mathcal{N}(p \mid 0, \Sigma).$$

Isso gera uma energia cinética quadrática:

$$T(p, q) = \frac{1}{2} p^\top \Sigma^{-1} p.$$

Interpretação

Como a métrica Σ é constante, a dinâmica ocorre em uma variedade Euclidiana.

Limitações do Euclidean HMC

Apesar de seu sucesso em aplicações difíceis, o Euclidean HMC apresenta duas fragilidades que ficam mais fortes em modelos hierárquicos:

- 1 Introdução de uma escala característica de comprimento via o tamanho de passo ϵ .
- 2 Limitação nas variações de densidade que podem ocorrer ao longo de uma transição.

Mensagem

Essas limitações aparecem porque modelos hierárquicos possuem curvatura e densidade variando fortemente ao longo do espaço de parâmetros.

Limitação 1: tamanho de passo

Como as equações de Hamilton raramente têm solução analítica, usa-se integração numérica com passo ϵ .

A estabilidade exige, aproximadamente:

$$\epsilon\sqrt{\lambda_i} < 2,$$

onde λ_i está associado à curvatura local.

Problema

No funil, há regiões com curvatura muito alta. Um passo adequado para a parte larga pode divergir na parte estreita.

Implicação prática

Divergências em HMC são sintomas de problemas geométricos da posterior.

Limitação 2: variação limitada de densidade




FIG. 6. Because the Hamiltonian, H , is conserved during each trajectory, the variation in the potential energy, V , is limited to the variation in the kinetic energy, T , which itself is limited to only $d/2$.

Durante cada trajetória:

$$H = T + V$$

permanece aproximadamente constante.

Limitação 2: variação limitada de densidade

Como

$$H = T + V,$$

se o Hamiltoniano é conservado, então:

$$\Delta V \approx -\Delta T.$$

No Euclidean HMC, a energia cinética tem variação limitada:

$$\Delta V = \Delta T \sim \frac{d}{2}.$$

Consequência

A energia potencial não pode variar arbitrariamente ao longo de uma trajetória.

Conectando o funil ao HMC




FIG. 7. Limited to moderate potential energy variations, the trajectories of Euclidean HMC, here with a unit metric $\Sigma = \mathbb{I}$, reduce to random walk behavior in hierarchical models. The resulting Markov chain explores more efficiently than Gibbs and Random Walk Metropolis (Figure 3), but not efficiently enough to make these models particularly practical.

Conectando o Funil ao HMC




FIG. 8. Depending on the common variance, σ^2 , from which the data were generated, the performance of a 10-dimensional one-way normal model (2) varies drastically between centered (CP) and non-centered (NCP) parameterizations of the latent parameters, θ_i . As the variance increases and the data become effectively more sparse, the non-centered parameterization yields the most efficient inference and the disparity in performance increases with the dimensionality of the model. The bands denote the quartiles over an ensemble of 50 runs with each run using Stan [20] configured with a diagonal metric and the No-U-Turn sampler. Both the metric and step size were adapted during warmup, and care was taken to ensure consistent estimates (Figure 9).

Conectando o funil ao HMC

- O funil possui enormes variações de densidade.
- Essas variações correspondem a grandes diferenças em energia potencial.
- O EHMC consegue alterar apenas uma quantidade limitada de energia ao longo da trajetória.

$$\Delta V \sim \frac{d}{2}.$$

Resultado

Mesmo com gradientes, o EHMC pode voltar a apresentar comportamento semelhante a um passeio aleatório.

O Riemannian HMC permite que a métrica varie com a posição:

$$p \mid q \sim \mathcal{N}(0, \Sigma(q)).$$

A energia cinética passa a ser:

$$T(p, q) = \frac{1}{2} p^\top \Sigma^{-1}(q) p - \frac{1}{2} \log |\Sigma(q)|.$$

Ideia

Usar uma métrica local para adaptar a dinâmica à curvatura da posterior.

Por que RHMC ajuda?

- A métrica local corrige correlações dependentes da posição.
- A dinâmica acompanha melhor regiões com curvatura variável.
- O termo $\log |\Sigma(q)|$ atua como um reservatório de energia.
- Isso permite atravessar regiões difíceis, como o funil.

SoftAbs metric

O artigo discute o uso da transformação SoftAbs para transformar a Hessiana em uma métrica bem comportada.

Por que RHMC ajuda?




FIG. 11. Without being limited to small variations in the potential energy, Riemannian Hamiltonian Monte Carlo with the SoftAbs metric admits transitions that explore the entirety of the funnel distribution, resulting in nearly independent transitions, and drastically smaller autocorrelations (compare with Figure 7, noting the different number of iterations).

Exemplo

Os autores consideram um modelo normal hierárquico com:

$$I = 800, \quad \mu = 8, \quad \tau = 3, \quad \sigma_i = 10.$$

Priors:

$$\mu \sim \mathcal{N}(0, 5^2),$$

$$\tau \sim \text{Half-Cauchy}(0, 2.5).$$

Comparam:

- Random Walk Metropolis;
- Metropolis-within-Gibbs;
- Euclidean HMC;
- parametrização centrada e não centrada.

Exemplo




FIG. 12. In order to ensure valid comparisons, each sampling algorithm was optimized but only so long as the resulting estimates were consistent with each other.

Algorithm	Parameterization	Step Size	Average Acceptance Probability	Time (s)	Time/ESS (s)
Metropolis	Centered	$5.00 \cdot 10^{-3}$	0.822	$4.51 \cdot 10^4$	1220
Gibbs	Centered	1.50	0.446	$9.54 \cdot 10^4$	297
EHMC	Centered	$1.91 \cdot 10^{-2}$	0.987	$1.00 \cdot 10^4$	16.2
Metropolis	Non-Centered	0.0500	0.461	398	1.44
Gibbs	Non-Centered	2.00	0.496	817	1.95
EHMC	Non-Centered	0.164	0.763	154	$2.94 \cdot 10^{-2}$

TABLE I. Euclidean Hamiltonian Monte Carlo significantly outperforms both Random Walk Metropolis and the Metropolis-within-Gibbs sampler for both parameterizations of the one-way normal model. The difference is particularly striking for the more efficient non-centered parameterization that would be used in practice.

- 1 Modelos hierárquicos criam geometrias posteriores difíceis.
- 2 O problema central é a curvatura local variável.
- 3 Métodos baseados em passeio aleatório exploram mal essas regiões.
- 4 HMC usa gradientes para construir trajetórias longas e coerentes.
- 5 Mesmo com HMC, parametrização centrada ou não centrada importa.
- 6 RHMC adapta a métrica à geometria local.

Betancourt, M. e Girolami, M. *Hamiltonian Monte Carlo for Hierarchical Models*. arXiv:1312.0906.

Obrigado!