

Stacking for Non-mixing Bayesian Computations: The Curse and Blessing of Multimodal Posteriors

Yao, Vehtari e Gelman (JMLR, 2022)

Guilherme C. Soares

2026

Ideia central do artigo

Problema

Distribuições posteriores multimodais fazem cadeias MCMC, aproximações variacionais ou métodos baseados em moda ficarem presas em regiões diferentes do espaço paramétrico.

Solução proposta

Rodar muitas inferências em paralelo, aceitar que elas podem não misturar entre modas, e combinar as cadeias por **Bayesian stacking**, escolhendo pesos que maximizam desempenho preditivo via leave-one-out.

Mensagem principal

Em modelos mal especificados, multimodalidade pode ser uma “benção”: combinar modas pode prever melhor do que tentar recuperar a posterior Bayesiana exata.

Por que multimodalidade é difícil?

- Regiões de alta probabilidade podem estar separadas por regiões de probabilidade muito baixa.
- Cadeias MCMC podem misturar bem *dentro* de um modo, mas não *entre* modas.
- Aproximações variacionais ou de Laplace tendem a capturar uma única região e subestimar incerteza.
- Mesmo se vários modas forem encontradas, calcular a massa posterior relativa de cada modo exige integrais difíceis.

*A pergunta deixa de ser apenas: “como amostrar a posterior?”
e passa a ser: “como combinar inferências não-misturadas de modo útil?”*

Configuração: várias cadeias não-misturadas

Suponha K cadeias ou clusters. A cadeia k contém S_k draws:

$$\theta_{k1}, \dots, \theta_{kS_k}.$$

Para qualquer função $h(\theta)$, o artigo considera o estimador ponderado:

$$\mathbb{E}[h(\theta) \mid w] \approx \sum_{k=1}^K \sum_{s=1}^{S_k} w_k S_k^{-1} h(\theta_{ks}), \quad \sum_{k=1}^K w_k = 1.$$

Caso usual

A média simples entre cadeias corresponde a $w_k = 1/K$.

Problema

Pesos iguais são convenientes, mas geralmente não são justificados quando cada cadeia ficou presa em uma região diferente.

Algoritmo proposto: chain stacking

- 1 **Rodar inferências paralelas:** MCMC, VI, Laplace ou métodos baseados em moda, com inicializações dispersas.
- 2 **Diagnosticar mistura dentro da cadeia:** usar split- $\hat{R}$ para verificar estabilidade local.
- 3 **Calcular desempenho preditivo:** aproximar $p_k(y_i | y_{-i})$ para cada cadeia ou cluster.
- 4 **Escolher pesos por stacking:** maximizar a log densidade preditiva leave-one-out da mistura.

Explorar modas em paralelo + combinar por previsão

Objetivo de stacking

$$\max_{\mathbf{w}} \sum_{i=1}^n \log \left(\sum_{k=1}^K w_k \int_{\Theta_k} p(y_i | \theta_k, M_k) p(\theta_k | M_k, \{y_{i'} : i' \neq i\}) d\theta_k \right)$$

O peso ótimo resolve:

$$w^* = \arg \max_{w \in \mathcal{S}_K} \sum_{i=1}^n \log \left(\sum_{k=1}^K w_k p_k(y_i | y_{-i}) \right) + \log p_{\text{prior}}(w),$$

com

$$\mathcal{S}_K = \left\{ w : 1 \geq w_k \geq 0, \sum_{k=1}^K w_k = 1 \right\}.$$

Aproximação LOO via PSIS

Reestimar o modelo n vezes para leave-one-out seria caro e ambíguo, pois remover um dado pode mover ou fundir modas.

O artigo define a posterior local leave-one-out por reponderação:

$$p_k(\theta \mid y_{-i}) := \frac{p_k(\theta \mid y)/p(y_i \mid \theta)}{\int p_k(\theta \mid y)/p(y_i \mid \theta) d\theta}.$$

Com Pareto smoothed importance sampling (PSIS):

$$p_k(y_i \mid y_{-i}) \approx \frac{\sum_{s=1}^{S_k} p(y_i \mid \theta_{ks}) r_{iks}}{\sum_{s=1}^{S_k} r_{iks}}.$$

Vantagem computacional

Depois das cadeias paralelas, o custo adicional é pequeno: somatórios PSIS e uma otimização no simplex de dimensão K .

Regularização dos pesos


Para evitar instabilidade quando cadeias têm previsões muito parecidas, os autores usam uma prior Dirichlet:

$$p_{\text{prior}}(w) = \text{Dirichlet} \left(\lambda \frac{S_{\text{eff},1}}{\sum_{k'} S_{\text{eff},k'}}, \dots, \lambda \frac{S_{\text{eff},K}}{\sum_{k'} S_{\text{eff},k'}} \right).$$

- $S_{\text{eff},k}$: tamanho efetivo da amostra da cadeia k .
- λ : controla quanto os pesos são puxados para pesos proporcionais a ESS.
- No artigo, uma escolha prática é $\lambda = 1.001$.


Intuição: modas boas, ruins e feias

- **Missing mode:** a posterior Bayesiana perde as modas reais do processo gerador.
- **Bad mode:** há uma moda espúria, por exemplo por troca de rótulos ou conflito prior-dados.
- **Ugly mode:** a posterior concentra em uma moda, embora os dados venham de uma mistura.



Stacking pode atribuir peso preditivo as modas relevantes e reduzir peso de regiões ruins.

Intuição: modas boas, ruins e feias



Diferença conceitual: Bayes exato vs stacking

Bayes exato

Busca integrar a posterior $p(\theta | y)$ corretamente, incluindo massas relativas das modas.

Stacking

Busca minimizar perda preditiva, combinando distribuições locais $p_k(\theta | y)$.

$$\text{Bayes: } p(\theta | y) \qquad \text{Stacking: } \sum_{k=1}^K w_k p_k(\theta | y).$$

Ponto-chave

Os pesos de stacking podem diferir das massas posteriores. Isso é uma escolha deliberada: o objetivo é preditivo, não reconstruir necessariamente a posterior exata.

Resultado teórico: quando stacking pode ganhar

Os autores analisam um exemplo com dados gerados por mistura de Cauchy:

$$y_i \sim \text{Cauchy}((2z_i - 1)a, 1), \quad z_i \sim \text{Bernoulli}(p_0),$$

mas ajustam um modelo mal especificado de uma única Cauchy:

$$y_i \sim \text{Cauchy}(\mu, 1).$$

Resultado

A posterior Bayesiana pode concentrar em apenas uma moda, enquanto stacking combina as modas e se aproxima melhor do processo gerador em termos preditivos.

Sob má especificação, multimodalidade pode ser informação útil, não apenas um defeito computacional.

Diferença conceitual: Bayes exato vs stacking




Figure 3: *Left: the deterministic function $\xi(a)$. For any $a > 2$ the posterior is bimodal with a large n if and only if $p_0 < \xi(a)$. Right: the elpd of the true data generating process and the asymptotic ($n \rightarrow \infty$) elpd of full Bayes and multi-chain stacking at $p_0 = 0.5$. When $p_0 = 0.5$, $a < 2$ the posterior is unimodally spiked at 0, and stacking is identical to Bayes.*

Exemplo 1: LDA em Pride and Prejudice

- Modelo de tópicos LDA com várias cadeias iniciadas aleatoriamente.
- As cadeias não misturam entre modas e produzem diferentes densidades preditivas.
- O stacking das 30 cadeias supera consistentemente as cadeias individuais.
- Também permite parar mais cedo: aumentar iterações melhora cadeias individuais, mas o stacked average é mais estável.

Exemplo 1: LDA em Pride and Prejudice




Figure 5: *The mean log predictive densities from 30 randomly initialized chains, and the stacked average of them, evaluated using both leave-one-word-out and independent test data. The number of topics L in the LDA model varies from 3 to 10, and each chain contains 2000 or 4000 iterations. Individual chains do not mix, and the best of them is invariably worse than stacking.*

LDA: ganho de early stopping

- $\hat{R}$ entre cadeias fica alto, mas split- $\hat{R}$ dentro das cadeias é bem menor.
- Isso indica que o problema está na transição entre modas, não na mistura local.
- BMA e pseudo-BMA tendem a colocar quase toda a massa em uma cadeia.
- Stacking mantém mais componentes efetivos e melhora a previsão fora da amostra.




Figure 6: Stacking benefits from early-stopped MCMC. We run LDA with $L = 10$ topics on 30 chains. As the number of iterations increase from 500 to 5000, the test lpd of individual chains increases, while the stacked average has a flatter slope, indicating we can stop early without losing much predictive power. Monitoring $\hat{R}$ and split-chain $\hat{R}$ of all pointwise likelihoods, we find that $\hat{R}$ is much bigger than split- $\hat{R}$. The bottom right shows the effective number of nonzero weights. BMA and pseudo-BMA put nearly all weight on one chain.

Exemplo 2: Gaussian Process Regression

- A posterior dos hiperparâmetros do GP pode ter múltiplas modas.
- Os autores comparam seleção de moda, aproximação de Laplace, importance resampling e stacking.
- Stacking combina previsões vindas de diferentes modas e apresenta melhor log densidade preditiva em dados de teste.

Modelo base:

$$y_i = f(x_i) + \varepsilon_i, \quad f \sim GP(0, K_{\alpha, \rho}), \quad \varepsilon_i \sim N(0, \sigma^2).$$

Exemplo 2: Gaussian Process Regression




Figure 7: The posterior distribution of hyperparameters $p(\rho, \alpha, \sigma|y)$ has at least two local modes. The left panel shows contours of the marginal posterior of ρ and α at fixed $\sigma = 0.25$. The middle panel shows draws from the posterior predictive distribution $f|y$ at the two hyperparameter modes. We can either pick these two modes as type-II MAP or locally approximate the posterior of hyperparameters at the modes by Laplace approximation or uniform-grid importance resampling. Then the resulting modes or local approximation can be combined according to stacking, mode height, or importance weighting. The right panel shows that stacking performs the best on test data log predictive densities for all schemes.

Outros exemplos empíricos

- **Regressão hierárquica:** barreiras entrópicas e modas locais podem surgir mesmo em parametrizações não centradas.
- **Horseshoe variable selection:** várias execuções de VI podem capturar regiões diferentes; stacking aproxima melhor a referência HMC/NUTS.
- **Redes neurais Bayesianas:** posterior altamente multimodal; stacking melhora ou estabiliza desempenho preditivo em MNIST.

Horseshoe




Figure 16: *The stacked VI posterior distribution matches HMC/NUTS draws reasonably well both marginally (left panel) and jointly (right panel) for the leukemia example, although individual runs are inaccurate. The graph displays two parameters β_{1834} and β_{4847} that have the largest absolute posterior means.*

Redes neurais Bayesianas




Figure 17: (1): The test mean log predictive densities of early stopped chains. Stacking performs consistently better than single-chain or other weighting methods. (2)–(4): The mean leave-one-out and test data log predictive densities of 50 individual chains (green dots), their stacking weights (size of the dot), and the test mean lpd from four weighting strategies when fitting a 40-hidden node neural network on MNIST. There were 4000 iterations per chain, and network parameters are initialized from $\text{uniform}(-50, 50)$, $(-5, 5)$, and $(-0.001, 0.001)$, respectively. Some individual changes in the overdispersed setting are out of the lower range.

Comparação com alternativas

Método	Ideia	Limitação
Média uniforme	$w_k = 1/K$	Depende das inicializações
BMA	Pesos por massa posterior	Integrais difíceis; sensível a modas ruins
Pseudo-BMA	Pesos por elpd individual	Pode concentrar em uma cadeia
Tempering	Facilitar transições entre modas	Tuning difícil; pode falhar em alta dimensão
Stacking	Pesos por previsão combinada	Não busca a posterior Bayesiana exata

Por que stacking é atraente?

É paralelizável, barato como pós-processamento e robusto à duplicação de cadeias que capturam o mesmo modo.

O que monitorar na prática?

- 1 **Mistura dentro da cadeia:** split- $\hat{R}$ e ESS por cadeia.
- 2 **Qualidade do PSIS:** diagnóstico Pareto $\hat{k}$.
- 3 **Número de cadeias efetivas:** muitos pesos quase zero indicam modas redundantes ou ruins.
- 4 **Evolução do elpd empilhado:** parar quando adicionar cadeias não melhora mais a previsão.
- 5 **Validação externa:** se possível, comparar em hold-out além do LOO.

- Se um modo preditivamente importante nunca for encontrado, stacking não consegue recuperá-lo.
- O método depende da qualidade da estimativa LOO/PSIS.
- Pesos preditivos não devem ser interpretados automaticamente como probabilidades posteriores das modas.
- Em modelos corretamente especificados e com amostragem perfeita, o objetivo Bayesiano e o objetivo preditivo podem divergir menos; em modelos mal especificados, a diferença é central.

Takeaways

- ➊ Multimodalidade mistura problemas computacionais e problemas de modelagem.
- ➋ Em vez de forçar uma única cadeia a transitar entre modas, podemos explorar regiões em paralelo.
- ➌ Stacking escolhe pesos para maximizar previsão, não para reproduzir massas posteriores.
- ➍ Em modelos mal especificados, combinar modas pode ser melhor do que Bayes exato concentrado em uma região.
- ➎ O método é especialmente útil como pós-processamento de MCMC, VI e aproximações locais.

Yao, Y., Vehtari, A., & Gelman, A. (2022). *Stacking for Non-mixing Bayesian Computations: The Curse and Blessing of Multimodal Posteriors*. *Journal of Machine Learning Research*, 23, 1–45.

Fim